

KI mit Python: Suche

Programmier Assignment 1

Sommersemester 2026

Überblick

Schreiben Sie ein Programm, das bestimmt, wie viele Grade zwei Schauspieler voneinander trennen.

Beispiel:

```
$ python degrees.py large
Loading data...
Data loaded.
Name: Emma Watson
Name: Jennifer Lawrence
3 degrees of separation.
1: Emma Watson and Brendan Gleeson starred in Harry Potter and the Order
   of the Phoenix
2: Brendan Gleeson and Michael Fassbender starred in Trespass Against Us
3: Michael Fassbender and Jennifer Lawrence starred in X-Men: First Class
```

Abgabe

- Gruppen von bis zu **5 Studierenden** bilden.
- **Die Abgabe ist für alle Studierenden verpflichtend.**
- Lösung über **Moodle** einreichen.
- Gruppe bei der Abgabe eindeutig angeben.
- Abgabefristen:
 - WWIMBIT23A: **30.04.2026, 12:00 Uhr**
 - WWIMBIT23B: **30.04.2026, 12:00 Uhr**

Hintergrund

Dem Spiel 'Sechs Grade der Trennung von Kevin Bacon' zufolge kann jede Person aus der Hollywood-Filmindustrie innerhalb von sechs Schritten mit Kevin Bacon in Verbindung gebracht werden, wobei jeder Schritt aus einem Film besteht, in dem zwei Schauspieler gemeinsam mitgespielt haben.

In dieser Aufgabe geht es darum, den kürzesten Pfad zwischen zwei beliebigen Schauspielern zu finden, indem eine Folge von Filmen gewählt wird, die sie verbindet. Der kürzeste Pfad zwischen Jennifer Lawrence und Tom Hanks beträgt beispielsweise 2: Jennifer Lawrence ist mit Kevin Bacon verbunden, da beide in 'X-Men: First Class' mitspielen, und Kevin Bacon ist mit Tom Hanks verbunden, da beide in 'Apollo 13' mitspielen.

Dies lässt sich als Suchproblem formulieren: Zustände sind Personen, Aktionen sind Filme, die von einem Schauspieler zu einem anderen führen. Anfangs- und Zielzustand werden durch die zwei zu verbindenden Personen definiert. Mithilfe der Breitensuche lässt sich der kürzeste Pfad von einem Schauspieler zum anderen finden.

Einstieg

1. Den bereitgestellten Code (im Moodle-Ordner **Programmier Assignments/PA1/Code**) herunterladen, der folgende Dateien enthält:
 - `degrees.py`
 - `util.py`
2. Die beiden Ordner `large/` und `small/` mit den Datensätzen aus dem Moodle-Ordner **Programmier Assignments/PA1/Daten** herunterladen.
3. Alle Dateien und Ordner in einem einzigen Projektverzeichnis auf dem eigenen Rechner ablegen.
4. Ein Terminal öffnen, in das Projektverzeichnis navigieren und eine virtuelle Python-Umgebung erstellen (siehe Vorlesungsunterlagen zur Python-Einführung).
5. Erforderliche Bibliotheken ggf. installieren.
6. **Empfehlung:** Testen Sie das Programm zunächst mit dem Datensatz `small/` – dieser ist deutlich kleiner und ermöglicht schnellere Rückmeldungen beim Entwickeln und Debuggen.

Den Datensatz verstehen

Insgesamt gibt es sechs Datensätze im CSV-Format: drei im Ordner `large/` und drei im Ordner `small/`. Beide Ordner haben dieselbe Struktur, `small/` ist jedoch ein vereinfachter Datensatz für Tests und Experimente.

Jeder Ordner enthält folgende drei Dateien:

- `people.csv`: Enthält Informationen zu Personen, darunter eine eindeutige `id`, den `name` und das `birth`-Jahr. Die IDs entsprechen Einträgen in der IMDb-Datenbank.
- `movies.csv`: Enthält Filme mit einer eindeutigen `id`, einem `title` und dem Erscheinungsjahr.
- `stars.csv`: Stellt Beziehungen zwischen Personen und Filmen dar. Jede Zeile enthält ein Paar aus `person_id` und `movie_id`, was bedeutet, dass die Person in dem Film mitgespielt hat.

Der Eintrag 102,104257 in `stars.csv` bedeutet z. B., dass die Person mit der ID 102 (Kevin Bacon) in dem Film mit der ID 104257 ('A Few Good Men') mitgespielt hat.

Den Code verstehen

Die Kernlogik des Projekts ist in `degrees.py` implementiert. Am Anfang der Datei sind mehrere wichtige Datenstrukturen definiert:

- `names`: Ein Dictionary, das Kleinbuchstaben-Namen auf eine Menge (`set`) von Personen-IDs abbildet – um Fälle abzudecken, in denen mehrere Personen denselben Namen tragen.
- `people`: Ein Dictionary, das jede Personen-ID auf ein weiteres Dictionary mit `name`, Geburtsjahr und einer Menge von Film-IDs abbildet.
- `movies`: Ein Dictionary, das jede Film-ID auf ein Dictionary mit Titel, Erscheinungsjahr und einer Menge von Personen-IDs abbildet.

Diese Datenstrukturen werden durch die Funktion `load_data` befüllt, die die CSV-Dateien einliest.

Die Hauptfunktion des Programms führt folgende Schritte aus:

1. Datensatz laden aus dem angegebenen Verzeichnis (`large/` oder `small/`), wählbar per Kommandozeilenargument.
2. Zwei Namen vom Nutzer abfragen.
3. `person_id_for_name` verwenden, um jeden Namen in eine eindeutige Personen-ID aufzulösen. Bei Mehrdeutigkeiten wird der Nutzer zur Klärung aufgefordert.
4. Die Funktion `shortest_path` aufrufen, um die kürzeste Verbindung zwischen den beiden Personen zu berechnen.
5. Die Folge der beteiligten Filme und Personen ausgeben.

Die Funktion `shortest_path` ist noch nicht implementiert. Ihre Aufgabe ist es, diese Funktion so zu vervollständigen, dass sie die minimale Anzahl an Verbindungen (Trennungsgrade) zwischen zwei Schauspielern korrekt berechnet.

Spezifikation

Vervollständigen Sie die Implementierung der Funktion `shortest_path` so, dass sie den kürzesten Pfad von der Person mit der ID `source` zur Person mit der ID `target` zurückgibt.

- Sofern ein Pfad existiert, soll die Funktion eine Liste zurückgeben, in der jedes Element das nächste `(movie_id, person_id)`-Paar auf dem Pfad von `source` zu `target` darstellt. Jedes Paar soll ein Tupel aus zwei Strings sein.
 - Beispiel: Gibt `shortest_path` den Wert `[(1, 2), (3, 4)]` zurück, bedeutet das: Source spielte in Film 1 mit Person 2, Person 2 spielte in Film 3 mit Person 4, und Person 4 ist das Ziel.
- Gibt es mehrere kürzeste Pfade, kann einer davon zurückgegeben werden.
- Existiert kein Pfad zwischen zwei Schauspielern, soll die Funktion `None` zurückgeben.
- Die Funktion `neighbors_for_person` darf verwendet werden: Sie erhält eine Personen-ID und gibt eine Menge von `(movie_id, person_id)`-Paaren aller Personen zurück, die gemeinsam mit der gegebenen Person in einem Film mitgespielt haben.

Es soll nichts anderes in der Datei verändert werden außer der Funktion `shortest_path`. Zusätzliche Hilfsfunktionen und der Import weiterer Python-Standardbibliotheken sind jedoch erlaubt.

Hinweise

- Während die Implementierung aus der Vorlesung das Ziel erst prüft, wenn ein Knoten aus der Frontier entfernt wird, lässt sich die Suche effizienter gestalten, indem das Ziel bereits beim Hinzufügen zur Frontier geprüft wird: Wird ein Zielknoten erkannt, muss er nicht zur Frontier hinzugefügt werden – die Lösung kann sofort zurückgegeben werden.
- Der Code aus den Vorlesungsbeispielen darf übernommen und angepasst werden. Die Datei `util.py` enthält die Implementierungen aus der Vorlesung für `Node`, `StackFrontier` und `QueueFrontier`, die verwendet und ggf. angepasst werden dürfen.
- **Nutzung von GenAI:** Die Nutzung von KI-Tools ist erlaubt. Es wird jedoch empfohlen, sich an die Hinweise zum bewussten Umgang mit GenAI aus der Vorlesung zu halten – der Lerneffekt liegt in der eigenständigen Auseinandersetzung mit dem Problem.